

Plano de Trabalho de Conclusão de Curso

Detecção de comportamento anormal auxiliada por GPU

UDESC - Centro de Ciências Tecnológicas
Departamento de Ciência da Computação
Bacharelado em Ciência da Computação - Integral
Turma 2011/1 - Joinville – Santa Catarina

Edward Boszczowski – devardeb@gmail.com

***Orientador: Gilmário Barbosa dos Santos –
gilmario@joinville.udesc.br***

Resumo – Este trabalho apresenta a implementação de uma técnica de detecção de comportamento anormal de pânico em uma multidão auxiliada por GPU (*Graphics Processing Unit*), a qual utiliza a GPU para a realização de suas tarefas: a segmentação, o cálculo do fluxo ótico e a etapa de classificação. A contribuição do trabalho reside no uso da GPU para detecção de comportamento anormal de multidão, o que no melhor dos esforços não pôde ser encontrado na literatura pesquisada. A fim de avaliar a técnica, serão medidos sua precisão e desempenho em vídeos compostos por imagens sintéticas.

Palavras-chave: *GPU, visão computacional, detecção de comportamento anormal de multidão.*

1. Introdução e Justificativa

A detecção de comportamentos anormais é um tema que vem ganhando cada vez mais importância na área de vigilância visual inteligente, crescendo o número de pesquisas feitas sobre o tema (Ermis, 2008). É ela que motiva a realização do

trabalho, sendo restrita a sua aplicação a situações que envolvem multidão e enfatizando a fuga por pânico, o comportamento anormal que deve ser detectado.

Na revisão de literatura realizada não foi encontrada uma definição formal para comportamento anormal, todavia percebeu-se que cada trabalho aborda um certo comportamento que considera como anormal, seja ele o pânico (Mehran, 2009), detecção de animais na rua (Ermis, 2008) ou mesmo a manifestação de atitudes que possam ser consideradas indícios da presença de terroristas em determinado local (Geng, 2006).

Conforme (Fridman, 2007) o comportamento de multidão é uma área de grande interesse, havendo diversos estudos na área de sociologia e psicologia, como também computacionalmente para simulação de multidões com ênfase em um determinado aspecto.

Na pesquisa realizada pôde-se perceber que a literatura a respeito de Técnicas de detecção de comportamento anormal ligadas à multidão é reduzida. Desta, alguns dos trabalhos realizados foram o de (Mehran, 2009) que foca no comportamento de pânico e usa um conceito sociológico denominado modelo de força social; e (Wu, 2005), que não menciona explicitamente o conceito de multidão, mas desenvolve um algoritmo de detecção de comportamento anormal tendo em mente a possibilidade de uma quantidade significativa de pessoas presentes no cenário, como na cena de uma pessoa correndo numa loja dentro de um *shopping*, ilustrada na figura 1.



Fonte: (Ermis, 2008)

Figura 1 – Cena de loja de shopping com pessoa correndo

Com base nos trabalhos pesquisados, observou-se uma gama variada de técnicas usadas para a detecção de comportamento anormal apoiando-se em métodos como *Hidden Markov Models* (HMM) (Bashir, 2007), *Multi-SVM (Support Vector Machine)* (Chen, 2007), Aprendizagem Estocástica (Boutterfroy, 2008), além de outros que lidam com parâmetros diversos, como por exemplo a existência de um modelo de força social (Mehran, 2009).

Trabalhos recentes como o de (Mehran, 2009) e o de (Andrade, 2007) usam na maioria técnicas não supervisionadas, as quais captam características globais da cena em vez de segmentar individualmente as pessoas na imagem. Isto se deve a limitações da segmentação individual, as quais são a maior complexidade computacional e a dificuldade na determinação de trajetórias e reconhecimento de atividades devido a oclusões, ocultamento dos objetos de interesse da cena (Geng, 2006)

O objetivo do trabalho é a implementação de um método de detecção de comportamento anormal fazendo uso de técnicas de programação em GPU baseado em procedimento encontrado na literatura. Encontrado nos algoritmos de detecção de comportamento anormal de multidões, o fluxo ótico é utilizado para determinar o

movimento das pessoas na cena e usualmente é associado a alguma técnica de classificação para determinar a presença de comportamento anormal.

Este trabalho de conclusão de curso faz uso de técnicas de GPGPU - *General Purpose Graphics Processing Unit* ou Unidade de Processamento Gráfico de Uso Geral, as quais têm por finalidade aumentar o desempenho de algoritmos usando características especiais da GPU, a qual serve como processador auxiliar da CPU (*Central Processing Unit* ou Unidade de Processamento Central). Em face das características singulares da GPU em relação a CPU, tais como arquitetura especializada para execução de aplicações paralelas em relação ao dado e grande capacidade de processamento aritmético, a GPU é um processador cada vez mais usado para aplicações de propósito geral. O crescente uso deste *hardware* abrange também a área de processamento de imagens e visão computacional, podendo ser notado em trabalhos como o exposto por esta monografia e os de (Ahn, 2005), (Fung, 2008) e (Fung, 2005).

Ainda que realizada busca exaustiva não foi encontrado um trabalho que realiza implementação em GPGPU de detecção de comportamento anormal de multidão. Entretanto, algumas técnicas usadas como parte do processo em trabalhos relacionados, como o fluxo ótico e a detecção de características (*features*) de uma imagem, já foram transportadas com sucesso para a GPU como relatam (Fung, 2008) e (Ahn, 2005)

Desse modo a contribuição deste trabalho é a implementação da técnica de detecção de comportamento anormal em GPU. Para tanto são realizados testes que demonstram a precisão e o desempenho do algoritmo implementado em cenários de complexidade diversa.

2. Objetivos

2.1 Objetivo Geral

O objetivo geral do trabalho é a própria implementação da técnica de detecção anormal de comportamento anormal de multidão em GPU, repousando o foco sob o comportamento de pânico.

2.2 Objetivos específicos

- Implementar a técnica de detecção de comportamento anormal em GPU usando bibliotecas prontas para as etapas de seu fluxo lógico como o fluxo ótico e a etapa de classificação;
- Avaliar a implementação quanto à corretude e ao desempenho em cenários de complexidade variável;

3. Metodologia

3.1 Geração dos vídeos

O algoritmo será testado em vídeos AVI (*Audio Video Interlaced*) compostos por imagens sintéticas. A opção pelo AVI se deve ao suporte dele pela biblioteca OpenCV, utilizada pelo trabalho. Com respeito as imagens sintéticas, elas conterão objetos representando pessoas e terão diversas resoluções, além da introdução do ruído sal-pimenta, para fins de avaliação da técnica.

3.2 Ambiente de software

Estando em posse dos vídeos e com base na proposta de solução formulada, as etapas do algoritmo serão implementadas na GPU usando bibliotecas (APIs – *Application Programming Interface*) prontas:

- Para a primeira etapa, a de segmentação por mistura de gaussianas, será utilizada a biblioteca cuBGS;
- Para o cálculo de fluxo ótico, a escolha é a API Folki-GPU;

A exceção é a etapa de classificação que não fará uso de nenhuma biblioteca pronta, tendo em vista que o procedimento escolhido para esta etapa é simples, sendo, deste modo, irrelevante o uso de bibliotecas para sua execução.

Por último, a biblioteca CUDA (*Compute Unified Device Architecture*) será utilizada para possibilitar o uso de GPGPU e o sistema operacional adotado é o Linux em virtude da biblioteca Folki-GPU usar a API deste sistema operacional.

3.3 Ambiente de Hardware

O ambiente de *hardware* disponível é composto de um computador com processador AMD Phenom II (4 núcleos – 3,2Ghz) com 4Gb de memória e uma placa de vídeo Geforce 8600.

3.4 Critérios para a análise da técnica

Para análise da técnica serão utilizados os critérios de precisão e tempo de execução do algoritmo

3.4.1 Precisão

A avaliação da precisão na determinação de comportamento anormal será feita por rotular manualmente o instante em que ocorre comportamento anormal e onde não

ocorre. Para isto partes (trechos) de um vídeo serão rotuladas como ocorrências positivas de pânico.

Para cada um dos vídeos a relação entre o número de quadros em que o algoritmo classifica o comportamento corretamente e o número total de quadros avaliados dará a margem de acerto do método. A média da taxa de acerto em uma determinada sequência irá resultar em um percentual que indicará o percentual de acerto da técnica.

Outro fator a ser analisado é o percentual dos quadros classificados corretamente como anormal em relação aos quadros que de fato apresentam tal comportamento. Por último, o percentual de falsos negativos dentre os quadros classificados como apresentando comportamento anormal será verificado. Este percentual é dado pela seguinte fórmula:

$$\frac{(N - C)}{N}$$

Onde N é o número de quadros classificados como tendo comportamento anormal e C é o número de quadros que foram corretamente rotulados como apresentando comportamento anormal.

3.4.2 Tempo de execução

Outro critério importante é a análise da curva de crescimento do tempo em relação a certos detalhes relevantes que devem ser levados em conta para avaliar a eficiência do método, a saber:

- **Resolução:** É importante mensurar como a curva de crescimento varia mediante a mudança de resolução dos vídeos, pois desta forma pode-se ter uma noção do impacto que a resolução tem no desempenho do método.
- **complexidade:** Características que variam entre vídeos, e são independentes das configurações de visualização definidas pelo usuário, como por exemplo a

quantidade de objetos, o número e a forma de movimentos realizados, implicam em cenas com níveis diferentes de complexidade. Tal fator deve ser ressaltado, pois ele pode afetar o tempo de execução do algoritmo. Por conseguinte, para cada vídeo gerado será atribuído um valor que representa sua complexidade para que se possa elaborar o gráfico que mostra o crescimento do tempo de execução em relação à complexidade da cena.

4. Cronograma Proposto

Etapas	2011																							
	Janeiro				Fevereiro				Março				Abril				Maio				Junho			
1										x														
2											x	x	x											
3													x	x	x									
4															x	x	x							
5																	x	x	x					x
6										x	x	x	x	x	x	x	x	x	x	x				x
7																								
8																								
9																								

1 – Geração dos vídeos

2 – Implementação da técnica de mistura de gaussianas

3 – Implementação do fluxo ótico em GPU

4 – Implementação da etapa de classificação da GPU

5 – Realização dos testes e avaliação dos resultados

6 – Escrita do TCC-2

5. Linha e Grupo de pesquisa

Este trabalho tem como foco a área de visão computacional e dentre as linhas de pesquisa existentes se situa na do grupo de pesquisa LARVA denominada

Fundamentos do processamento Gráfico e da interação, a qual tem a área gráfica como fim.

6. Forma de Acompanhamento/Orientação

O acompanhamento do orientador será feito por meio de reuniões semanais, uma por semana, aonde o aluno se encarrega de mostrar o que fez naquela semana seja por meio de um relatório, seja por uma demonstração do que está implementado ou por outra maneira em que seja evidente o progresso tido. Tal frequência pode aumentar, caso haja alguma dúvida ou dificuldade por parte do aluno e seja necessário o contato pessoal como forma de resolução da questão.

7. Referências Bibliográficas

1. Ahn, IkkJin; Lehr Michael. Image Processing on the GPU. University of Pennsylvania, 2005. Disponível em: <www.cis.upenn.edu/~suvenkat/700/projects/alt.pdf>. Acesso em: 18 mar. 2010
2. Bashir, Faisal I.; Khokhar, Ashfaq a.; Schonfeld, Dan. IEEE Transactions on Image Processing. Local: IEEE, v.16, n.7, jun. 2007, Object Trajectory-Based Activity Classification and Recognition using Hidden Markov Models. In: **Proceedings of the...** . Geneva Public.: IEEE, 2007.
3. Bouttefroy, P.L.M; Bouzerdoum, A; Phung, S.L. Beghdadi, Abnormal Behavior Detection using a Multi-Modal Stochastic Learning Approach. In: International Conference on Sensor Networks and Information Processing, 2008, Sydney, **Proceedings...** Geneva.: IEEE, 2008. pp. 121 – 126.
4. Chen, Yufen et al. Abnormal Behavior Detection by Multi-SVM-Based Bayesian Network. In: International Conference on Information Acquisition, 2007, Seogwipo, **Proceedings...** Geneva.: IEEE, 2007. pp. 298 – 303.
5. Ermis, Erhan Baki, et al. MOTION SEGMENTATION AND ABNORMAL BEHAVIOR DETECTION VIA BEHAVIOR CLUSTERING. In: IEEE International Conference

on Distributed Smart Cameras, 2, 2008, Stanford, **Proceedings...** Geneva.: IEEE, 2008. pp. 1 – 10.

6. Fridman, Natalie . **Modeling Crowd Behavior Based on Social Comparison Theory** [Tese de Mestrado], Bar Ilan Univerity, 2007

7. Fung, James; Mann, Steve. Computer Vision on the GPU. In: NVIDIA Corporation. **GPU Gems 2**. NVIDIA, 2005. pp.651-558.

8. Fung, James. USING GRAPHICS DEVICES IN REVERSE: GPU-BASED IMAGE PROCESSING AND COMPUTER VISION. In: IEEE International Conference on Multimedia & Expo, num, 2008, Hannover, **Proceedings of the ...** Geneva.: IEEE, 2008. pp. x – y.

9. Geng, Xin et al. **Abnormal behavior detection for early warning of terrorist attack**. Springer, 2006. pp. 1002-1009.

10. Mehran, Ramin; Oyama, Alexis; Shah, Mubarak. Abnormal Crowd Behavior Detection using Social Force Model. In: IEEE International Conference on Computer Vision and Pattern Recongition, 2009, Miami, **Proceedings ...** Geneva: IEEE, 2009. pp. 935-942.

11. NVIDIA Corporation. **NVIDIA CUDA Programming Guide versão 3.0**. 2008. 102p. Disponível em: <http://developer.download.nvidia.com/compute/cuda/3_0/toolkit/docs/NVIDIA_CUDA_ProgrammingGuide.pdf> Acesso em: 09 abr. 2010.

12. Wu, Xinyu et al. A Detection System for Human Abnormal Behavior. in: IEEE/RSJ International Conference on Intelligent Robots and Systems, 2005, **Proceedings ...** Geneva: IEEE, 2005. pp. 1204-1208.

UNIVERSIDADE DO ESTADO DE SANTA CATARINA-UDESC
CENTRO DE CIÊNCIAS TECNOLÓGICAS – CCT
DEPARTAMENTO DE CIÊNCIA DA COMPUTAÇÃO -DCC



Marcelo da Silva Hounsell